

Deep Learning vs. Machine Learning Clássico na Predição de Evasão Estudantil

Modalidade 1 — Trabalho Individual

Pode a Deep Learning superar o ML clássico publicado por Villar & de Andrade (2024)?

Evasão: o problema que queremos antecipar

A evasão no ensino superior gera custo social, econômico e institucional.
Identificar alunos em risco cedo permite intervenções de apoio direcionadas.

3 classes

Dropout · Enrolled ·
Graduate


4.424

alunos (uma instituição,
2008–2019)

34 variáveis

demográficas,
socioeconômicas,
acadêmicas

Tarefa de classificação multiclasse. Métrica central: F1 por classe (não acurácia), por causa do desbalanceamento.



Distribuição desbalanceada: Enrolled é a minoria (17,9%).

O que os autores originais fizeram

Artigo-base

Villar & de Andrade (2024).

“Supervised ML algorithms for predicting student dropout and academic success.” Discover AI, 4(1).

Reutiliza o dataset de Martins et al. (2021) / Realinho et al. (2022).

Modelos clássicos: DT, SVM, RF, Gradient Boosting, XGBoost, CatBoost, LightGBM + SMOTE + Optuna.

Melhor resultado publicado

CatBoost + Optuna (com SMOTE)

$F1 \approx 0,86-0,88$

Nossa missão: tentar superar isso com Deep Learning — e avaliar se esse número resiste a um teste rigoroso.

Literatura que sustenta o trabalho

Domínio — evasão & EDM

- Realinho et al. (2022) — dataset e tarefa.
- Martins et al. (2021) — predição precoce no IPP.
- Villar & de Andrade (2024) — estudo comparativo (artigo-base).
- Niyogisubizo et al. (2022) — ensemble empilhado p/ evasão.
- Rastrollo-Guerrero et al. (2020) — revisão de ML em desempenho estudantil.

Técnica — DL & dados tabulares

- Guo & Berkhahn (2016) — entity embeddings.
- Grinsztajn et al. (2022) — por que árvores ainda vencem em tabular.
- Shwartz-Ziv & Armon (2022) — “DL is not all you need”.
- Arik & Pfister (2021) — TabNet.
- Chawla et al. (2002) — SMOTE p/ desbalanceamento.

Descrição do dataset

Fonte	UCI Machine Learning Repository #697 (CC BY 4.0); lido via URL pública no Pandas
Origem	Instituto Politécnico de Portalegre (Portugal), bases agregadas
Período	Matrículas entre 2008 e 2019
Volume	4.424 alunos × 34 variáveis + alvo
Variáveis	Demográficas, socioeconômicas, macroeconômicas e acadêmicas (1º/2º sem.)
Alvo	Dropout (32,1%) · Enrolled (17,9%) · Graduate (49,9%)
Qualidade	Sem valores ausentes; classe Enrolled é ambígua e difícil de separar

Protocolo honesto + arquitetura de DL

1 · Avaliação sem vazamento


- Split estratificado 70/15/15 ANTES de qualquer balanceamento.
- StandardScaler ajustado só no treino.
- Pesos de classe / SMOTE aplicados só no treino.
- Baselines clássicos (RF, XGBoost, LightGBM) reproduzidos no mesmo split.

2 · Modelo de Deep Learning

- Entity embeddings para 18 variáveis categóricas (Guo & Berkahn).
- MLP: camadas 256 → 128 → 64 com BatchNorm, ReLU e Dropout(0,35).
- Perda ponderada por classe + label smoothing; AdamW + early stopping.
- Ensemble de 5 sementes (média das probabilidades).

Comparação justa no protocolo honesto

Modelo	F1 Drop	F1 Enr	F1 Grad	Macro-F1	AUC
Random Forest	0,82	0,47	0,88	0,722	0,910
XGBoost ★	0,81	0,56	0,87	0,747	0,910
LightGBM	0,80	0,53	0,87	0,735	0,904
Deep Learning (Emb-MLP ×5)	0,79	0,54	0,84	0,721	0,893



Boosting (XGBoost) lidera por margem pequena; o DL fica competitivo, mas não supera — coerente com a literatura de dados tabulares (Grinsztajn et al., 2022).

Os 0,86–0,88 publicados não se replicam

0,86

F1 publicado
(SMOTE antes do split → vazamento)

~0,75


Teto real macro-F1
(todos os métodos, avaliação honesta)

= 0,11

superestimação removida
ao corrigir o protocolo

Contribuição do projeto: um benchmark confiável. Os números originais serviam de referência para decisão real — e estavam inflados.

Onde o Deep Learning agrega valor: alerta precoce



AUC = 0,923

score de risco binário: Dropout vs. resto

O custo de não detectar quem evade (falso negativo) é maior que o de apoiar quem não precisava.

A probabilidade do DL permite ajustar o limiar para priorizar recall:

- Limiar 0,50 → recall 0,72 · precisão 0,90
- Limiar 0,21 → recall 0,85 · precisão 0,75 (modo intervenção)

Cada ponto de recall = um aluno em risco identificado a tempo.

Leitura crítica dos resultados

Por que árvores vencem

Em dados tabulares heterogêneos, gradient boosting capta interações de forma mais eficiente em amostras moderadas — efeito documentado na literatura.

Gargalo: classe Enrolled

É intrinsecamente ambígua (ainda matriculado). Nenhum modelo passa de $F1 \approx 0,56$; SMOTE não ajudou o MLP.

Vieses & riscos

Variáveis socioeconômicas e de gênero podem induzir decisões enviesadas; alerta deve apoiar, não rotular alunos.

Limitações

Dataset único (1 instituição, 2008–2019); sem validação temporal/externa; resultados de uma única partição.

Resultado negativo é resultado: a honestidade metodológica é parte do achado.

CONCLUSÃO

Síntese e próximos passos

- ✓ DL ficou competitivo (macro-F1 0,72; AUC 0,89) mas não superou o boosting (0,75 / 0,91).
- ✓ A real contribuição: expor o vazamento do baseline e fixar um teto honesto (~0,75).
- ✓ O DL entrega valor operacional no alerta precoce (AUC 0,923, limiar ajustável).
- Próximos passos: CV repetida com IC, FT-Transformer/TabNet, calibração e auditoria de equidade.

Repositório (notebook + dados + README): [github.com/\[seu-usuario\]/evasao-deep-learning](https://github.com/[seu-usuario]/evasao-deep-learning)