

# Deep Learning vs. Machine Learning Clássico na Predição de Evasão Estudantil

## Modalidade 1 — Trabalho Individual

Pode a Deep Learning superar o ML clássico publicado por Villar & de Andrade (2024)?

# Evasão: o problema que queremos antecipar

A evasão no ensino superior gera custo social, econômico e institucional.  
Identificar alunos em risco cedo permite intervenções de apoio direcionadas.

**3 classes**

Dropout · Enrolled ·  
Graduate


**4.424**

alunos (uma instituição,  
2008–2019)

**34 variáveis**

demográficas,  
socioeconômicas,  
acadêmicas

**Tarefa de classificação multiclasse.** Métrica central: F1 por classe (não acurácia), por causa do desbalanceamento.



*Distribuição desbalanceada: Enrolled é a minoria (17,9%).*

# O que os autores originais fizeram

## Artigo-base

**Villar & de Andrade (2024).**

“Supervised ML algorithms for predicting student dropout and academic success.” Discover AI, 4(1).

Reutiliza o dataset de Martins et al. (2021) / Realinho et al. (2022).

Modelos clássicos: DT, SVM, RF, Gradient Boosting, XGBoost, CatBoost, LightGBM + SMOTE + Optuna.

## Melhor resultado publicado

**CatBoost + Optuna (com SMOTE)**

**$F1 \approx 0,86-0,88$**

Nossa missão: tentar superar isso com Deep Learning — e avaliar se esse número resiste a um teste rigoroso.

# Literatura que sustenta o trabalho

## Domínio — evasão & EDM

- Realinho et al. (2022) — dataset e tarefa.
- Martins et al. (2021) — predição precoce no IPP.
- Villar & de Andrade (2024) — estudo comparativo (artigo-base).
- Niyogisubizo et al. (2022) — ensemble empilhado p/ evasão.
- Rastrollo-Guerrero et al. (2020) — revisão de ML em desempenho estudantil.

## Técnica — DL & dados tabulares

- Guo & Berkhahn (2016) — entity embeddings.
- Grinsztajn et al. (2022) — por que árvores ainda vencem em tabular.
- Shwartz-Ziv & Armon (2022) — “DL is not all you need”.
- Arik & Pfister (2021) — TabNet.
- Chawla et al. (2002) — SMOTE p/ desbalanceamento.

# Descrição do dataset

|           |                                                                                  |
|-----------|----------------------------------------------------------------------------------|
| Fonte     | UCI Machine Learning Repository #697 (CC BY 4.0); lido via URL pública no Pandas |
| Origem    | Instituto Politécnico de Portalegre (Portugal), bases agregadas                  |
| Período   | Matrículas entre 2008 e 2019                                                     |
| Volume    | 4.424 alunos × 34 variáveis + alvo                                               |
| Variáveis | Demográficas, socioeconômicas, macroeconômicas e acadêmicas (1º/2º sem.)         |
| Alvo      | Dropout (32,1%) · Enrolled (17,9%) · Graduate (49,9%)                            |
| Qualidade | Sem valores ausentes; classe Enrolled é ambígua e difícil de separar             |

# Protocolo honesto + arquitetura de DL

## 1 · Avaliação sem vazamento


- Split estratificado 70/15/15 ANTES de qualquer balanceamento.
- StandardScaler ajustado só no treino.
- Pesos de classe / SMOTE aplicados só no treino.
- Baselines clássicos (RF, XGBoost, LightGBM) reproduzidos no mesmo split.

## 2 · Modelo de Deep Learning

- Entity embeddings para 18 variáveis categóricas (Guo & Berkahn).
- MLP: camadas 256 → 128 → 64 com BatchNorm, ReLU e Dropout(0,35).
- Perda ponderada por classe + label smoothing; AdamW + early stopping.
- Ensemble de 5 sementes (média das probabilidades).

# Comparação justa no protocolo honesto

| Modelo                            | F1 Drop     | F1 Enr      | F1 Grad     | Macro-F1     | AUC          |
|-----------------------------------|-------------|-------------|-------------|--------------|--------------|
| Random Forest                     | 0,82        | 0,47        | 0,88        | 0,722        | 0,910        |
| <b>XGBoost ★</b>                  | <b>0,81</b> | <b>0,56</b> | <b>0,87</b> | <b>0,747</b> | <b>0,910</b> |
| LightGBM                          | 0,80        | 0,53        | 0,87        | 0,735        | 0,904        |
| <b>Deep Learning (Emb-MLP ×5)</b> | <b>0,79</b> | <b>0,54</b> | <b>0,84</b> | <b>0,721</b> | <b>0,893</b> |



**Boosting (XGBoost) lidera por margem pequena;** o DL fica competitivo, mas não supera — coerente com a literatura de dados tabulares (Grinsztajn et al., 2022).

## Os 0,86–0,88 publicados não se replicam

0,86

F1 publicado  
(SMOTE antes do split → vazamento)

~0,75

Teto real macro-F1  
(todos os métodos, avaliação honesta)


= 0,11

superestimação removida  
ao corrigir o protocolo

*Contribuição do projeto: um benchmark confiável. Os números originais serviam de referência para decisão real — e estavam inflados.*



## Onde o Deep Learning agrega valor: alerta precoce



### AUC = 0,923

score de risco binário: Dropout vs. resto

O custo de não detectar quem evade (falso negativo) é maior que o de apoiar quem não precisava.

**A probabilidade do DL permite ajustar o limiar para priorizar recall:**

- Limiar 0,50 → recall 0,72 · precisão 0,90
- Limiar 0,21 → recall 0,85 · precisão 0,75 (modo intervenção)

*Cada ponto de recall = um aluno em risco identificado a tempo.*

## Leitura crítica dos resultados

### Por que árvores vencem

Em dados tabulares heterogêneos, gradient boosting capta interações de forma mais eficiente em amostras moderadas — efeito documentado na literatura.

### Gargalo: classe Enrolled

É intrinsecamente ambígua (ainda matriculado). Nenhum modelo passa de  $F1 \approx 0,56$ ; SMOTE não ajudou o MLP.

### Vieses & riscos

Variáveis socioeconômicas e de gênero podem induzir decisões enviesadas; alerta deve apoiar, não rotular alunos.

### Limitações

Dataset único (1 instituição, 2008–2019); sem validação temporal/externa; resultados de uma única partição.

*Resultado negativo é resultado: a honestidade metodológica é parte do achado.*

## CONCLUSÃO

# Síntese e próximos passos

- ✓ DL ficou competitivo (macro-F1 0,72; AUC 0,89) mas não superou o boosting (0,75 / 0,91).
- ✓ A real contribuição: expor o vazamento do baseline e fixar um teto honesto (~0,75).
- ✓ O DL entrega valor operacional no alerta precoce (AUC 0,923, limiar ajustável).
- Próximos passos: CV repetida com IC, FT-Transformer/TabNet, calibração e auditoria de equidade.

Repositório (notebook + dados + README): [github.com/fcristina72-ai/Trabalho\\_Final\\_DL](https://github.com/fcristina72-ai/Trabalho_Final_DL)